

原型用户测试与需求验证方案

可解释知识图谱补全与审核工作台

测试版本 V1.0 | 适用于当前可点击低保真原型

方案用途

用可观察、可计量的用户任务验证候选排序、模型置信评分、关键路径解释、三态审核与结果导出是否具有实际价值，并据此决定正式 PRD 和高保真设计的范围。

当前原型使用模拟候选、评分和路径。本次测试验证的是业务流程、信息表达与用户行为，不用于证明 UBERT RM 模型已经达到生产可用水平。

核心产出包括：任务完成记录、三组对照数据、用户访谈证据、需求假设验证结论和原型迭代清单。

一 测试目标与验证范围

本次测试同时覆盖可用性验证和价值验证。可用性验证关注用户能否完成导入、创建任务、审核和导出闭环；价值验证关注模型评分与路径证据是否提升审核效率、准确性和判断信心。

验证层次	核心问题	主要证据
可用性	用户是否理解页面、术语、状态和操作	任务完成率、关键错误、观察记录、口述反馈
效率	辅助信息是否减少判断时间	单条耗时、单位时间正确审核量
质量	辅助信息是否改善或至少不损害判断质量	准确率、暂缓合理性、审核一致性
解释价值	路径是否帮助理解而非增加负担	C 组相对 B 组变化、有用性评分、访谈

验证层次	核心问题	主要证据
闭环价值	审核结果能否进入后续工作	导出成功率、字段完整性、返工意见

不在本轮验证范围

- 不评价 UBERT RM 在 CN15K、NL27K 上的离线模型指标。
- 不验证真实后端性能、并发、账号权限、数据库持久化或生产图谱写入。
- 不以模拟进度和模拟导出证明系统已经具备工程可用性。
- 不直接推导医疗、金融等专业场景的适用性。

主指标

单位时间内正确完成审核的候选数量 = 正确判断条数 ÷ 有效审核时间（分钟）。该指标同时约束速度和质量。

二 待验证需求假设

编号	需求假设	优先级	验证证据
H1	候选生成与排序减少用户自行寻找缺失事实的成本	P0	流程访谈、排序使用方式、单位时间完成量
H2	模型置信评分帮助安排审核顺序并辅助判断	P0	B 组相对 A 组的效率、准确率与信心变化
H3	2 至 3 条关键路径在评分之外提供增量价值	P0	C 组相对 B 组的效率、准确率和有用性
H4	接受、驳回、暂缓覆盖主要审核决策	P0	状态分布、无法归类的判断、访谈
H5	用户不会把高模型评分直接等同于事实正确	P0	高分错误样本的接受率与口述原因
H6	无路径时用户仍能理解状态并继续处理	P0	无路径任务完成率、暂缓率、错误数
H7	筛选、撤销和连续审核支持高频工作	P1	操作成功率、回退次数、用户评价
H8	结构化审核结果能够衔接后续图谱更新或分析	P0	导出成功率、字段可用性和缺失字段反馈

三 测试方法与实验设计

总体方法

采用一次约 50 至 60 分钟的一对一主持式测试。每位参与者先完成当前原型的端到端任务，再完成 A、B、C 三种信息条件下的候选判断，最后填写量表并参加半结构化访谈。

条件	参与者可见信息	验证目的
A 基线	候选事实	建立纯人工判断基线
B 评分	候选事实 + 模型置信评分	验证评分的辅助价值与盲从风险
C 解释	候选事实 + 评分 + 2 至 3 条关键路径	验证路径相对于评分的增量价值

实验结构

- 采用被试内设计，每位参与者均体验 A、B、C 三种条件。
- 每种条件判断 6 条候选，共 18 条；正确、错误和证据不足样本比例保持一致。
- 条件顺序使用 ABC、BCA、CAB 等平衡顺序轮换，避免固定顺序带来的学习效应。
- 同一事实只向同一参与者展示一次，避免记忆答案；不同参与者使用难度等价的题组。
- 主持人不解释候选是否正确，不暗示模型分数高低对应的判断。

样本量

首轮招募 6 至 8 名目标用户，用于发现主要可用性问题并观察效果方向。该样本量不足以给出稳定的统计显著性结论，因此报告应同时呈现每位参与者数据、均值、中位数和原始观察。若首轮结果支持继续开发，再扩展至至少 18 至 24 人进行定量验证。

解释原则

首轮测试的结论使用“支持、部分支持、未支持、证据不足”，不使用“证明有效”。

四 参与者招募与筛选

要求	标准
目标人群	知识图谱方向研究生、研究人员、知识工程师或数据维护人员

要求	标准
必要经验	理解实体、关系、三元组；做过图谱构建、补全、标注或维护中的至少一项
建议构成	3 至 4 名偏研究用户 + 3 至 4 名偏工程或数据维护用户
排除条件	参与当前原型设计、已知全部测试答案，或无法独立判断测试领域事实
领域要求	若测试材料使用专业领域数据，参与者需具备相应领域知识

招募筛选题

1. 你是否理解知识图谱中的实体、关系和三元组？请用一个例子说明。
2. 过去一年是否参与过知识图谱构建、补全、质量检查或数据标注？承担了什么任务？
3. 你通常依据哪些信息判断一个候选事实是否可以写入知识图谱？
4. 你是否使用过候选排序、置信评分、路径解释或类似审核工具？
5. 你是否熟悉本次测试材料涉及的领域？

五 测试材料与样本准备

材料	数量/要求	用途
可点击低保真原型	当前版本，测试前冻结版本号	完成端到端流程任务
候选判断题	18 条/人，另备 3 条练习题	完成 A、B、C 条件比较
参考答案	每条含接受、驳回或暂缓及理由	计算正确率和分歧
主持人任务单	统一指令、追问和提示规则	减少主持人差异
计时与观察表	每人一份	记录时间、路径和错误
测试后问卷	7 级量表 + 开放题	记录主观评价
访谈提纲	8 至 10 个问题	解释行为数据和发现缺失需求

样本类型配额

样本类型	建议数量	主要观察
高分且正确，有清晰路径	3	正常辅助流程
高分但错误	3	是否盲从模型评分

样本类型	建议数量	主要观察
低分但正确	3	是否只按分数判断
无有效路径	3	解释缺失时能否继续
关系或实体容易混淆	3	驳回原因是否够用
证据不足	3	暂缓是否符合真实判断

参考答案建立规则

1. 由两名熟悉数据的评审者独立标注接受、驳回或暂缓，并写出依据。
2. 两人一致时形成初始参考答案；不一致时由第三名评审者讨论裁决。
3. 对开放世界下无法确认的事实保留“暂缓”，不得强行标成错误。
4. 记录答案来源、更新时间和争议说明，测试后仍允许复核。

数据要求

模型分数与路径可以是模拟数据，但必须与候选难度匹配，并明确保留高分错误、低分正确和无路径样本。

六 测试环境与人员分工

角色	职责
主持人	宣读说明、发放任务、控制提示、完成访谈
观察员	计时、记录操作路径、错误、原话和非语言反应
数据负责人	准备题组、参考答案、编号和条件顺序
产品负责人	测试后汇总证据、判断假设并维护迭代清单

现场或远程测试均可。建议使用统一电脑和浏览器窗口，关闭无关页面；远程测试需共享屏幕并征得录制同意。每次开始前清空原型状态，确认文件选择、任务状态、审核按钮、撤销和导出均能正常演示。

七 单场测试流程

阶段	时间	主持人动作	记录重点
开场与说明	3 分钟	说明目的、录制与无对错原则	参与者同意
背景访谈	5 分钟	了解经验、现有流程和判断依据	角色、频率、痛点
练习	3 分钟	用非正式样本熟悉三态审核	术语理解
端到端任务	15 分钟	发放任务，不主动指导	完成率、错误、提示
A/B/C 判断	18 分钟	按指定顺序展示 18 条候选	答案、耗时、信心
量表	5 分钟	参与者独立评分	评分与备注
访谈	10 分钟	围绕行为追问原因	需求与改进建议
结束	2 分钟	说明后续用途并致谢	补充意见

主持人开场词

建议原文

今天测试的是产品原型，不是在测试你。请按照你真实工作的判断方式操作，并尽量说出你正在关注什么。遇到不确定情况可以正常选择暂缓。原型中的候选、评分和路径是用于测试流程的模拟数据。除非任务无法继续，我不会在过程中告诉你下一步。

提示规则

- 参与者停顿 30 秒后，先问“你现在在找什么？”而不是直接告诉入口。
- 参与者明确表示无法继续时，可以给一级提示“请看看页面上与当前任务相关的区域”。
- 一级提示后仍无法继续，再给具体入口提示，并记录为需要帮助完成。
- 任何提示都要记录发生时间、提示级别及触发原因。

八 端到端任务脚本

任务	给参与者的情境	成功标准	观察点
T1 导入	你收到一份待处理图谱 CSV，请导入并确认能否用于补全。	完成文件选择并读懂校验结果	字段说明、错误定位、下一步入口
T2 创建任务	请创建一个尾实体补全任务，并设置你认为合适的候选数量。	任务创建且理解主要配置	术语、默认值、研究参数暴露
T3 开始审核	任务已完成，请找到需要优先处理的候选并进入审核。	进入候选审核页并说明排序依据	状态理解、入口、排序认知
T4 判断候选	请结合页面信息处理当前候选。	完成接受/驳回/暂缓并说明依据	评分、路径、邻域和备注使用
T5 无路径	请处理一条没有有效路径的候选。	理解解释缺失且仍能作出合理决定	是否误以为无路径等于错误
T6 更正	你发现刚才判断有误，请恢复并重新处理。	成功撤销或修改状态	可发现性和反馈
T7 导出	请导出可用于后续图谱更新的结果。	选择仅已接受并理解导出范围	数量、字段、完成反馈

九 A/B/C 候选判断任务

每条候选显示后立即开始计时。参与者选择接受、驳回或暂缓，填写或口述原因，再报告判断信心。进入下一题时停止计时。主持人不要求参与者在每题进行长篇解释，以免口述本身显著增加耗时。

记录字段	取值与说明
participant_id	匿名参与者编号
condition	A、B 或 C
item_id / item_type	候选编号及样本类型
decision	接受、驳回或暂缓
reference_decision	参考答案
correct	一致为 1，不一致为 0；争议样本单独分析

记录字段	取值与说明
time_seconds	从候选完整显示到确认决定
confidence	1 至 7 分，1 为完全没信心，7 为非常有信心
path_opened	是否查看/展开路径，仅 C 条件
reason / note	结构化原因及参与者备注

题组平衡示例

参与者	条件顺序	题组映射
P01	A→B→C	A 用题组 1，B 用题组 2，C 用题组 3
P02	B→C→A	B 用题组 1，C 用题组 2，A 用题组 3
P03	C→A→B	C 用题组 1，A 用题组 2，B 用题组 3
P04	C→B→A	C 用题组 1，B 用题组 2，A 用题组 3
P05	B→A→C	B 用题组 1，A 用题组 2，C 用题组 3
P06	A→C→B	A 用题组 1，C 用题组 2，B 用题组 3

十 指标口径与计算方法

指标	计算口径	用途
任务完成率	独立完成任务数 ÷ 任务总数	判断流程可用性
关键任务成功率	完成 T1、T4、T7 的人数 ÷ 参与者数	判断闭环是否成立
准确率	正确判断数 ÷ 有明确参考答案的判断数	衡量判断质量
平均/中位耗时	各条件单条候选 time_seconds	识别效率变化及离群值
正确审核吞吐量	正确判断数 ÷ 有效审核分钟数	本轮主指标
暂缓率	暂缓数 ÷ 全部判断数	观察证据不足时的处理方式
高分错误接受率	被接受的高分错误样本 ÷ 高分错误样本	识别自动化偏见
路径增量	C 条件指标 - B 条件指标	验证路径在评分之外的价值
提示依赖率	需要一级或二级提示的任务数 ÷ 任务总数	定位入口和文案问题
导出成功率	独立完成正确范围导出的人数 ÷ 参与者数	验证结果闭环

同时报告均值、中位数、最小值、最大值和每位参与者数据。首轮样本较小时不依赖单一均值，也不将个别极端结果外推为总体结论。

十一 成功标准与判断规则

假设	建议支持标准	否定或风险信号
H1 排序价值	多数用户认可候选队列价值；端到端流程可独立完成	仍依赖外部检索生成候选，或无法理解优先级
H2 评分价值	B 相对 A 的正确吞吐量改善，准确率不明显下降	高分错误接受率明显上升或用户称其为正确概率
H3 路径价值	C 相对 B 的正确吞吐量、准确率或信心至少一项改善，且有用性 $\geq 4/7$	路径增加耗时且不改善质量，多数用户认为难懂
H4 三态决策	至少 90%的判断可自然归入接受、驳回、暂缓	频繁需要新增状态或绕过现有动作
H6 无路径处理	至少 80%的用户无需具体提示完成无路径任务	把无路径直接理解为错误或无法继续
H8 导出闭环	至少 80%的用户正确导出仅已接受结果，并认可字段可用	范围选择错误、字段缺失或需大量手工返工

上述阈值是 MVP 阶段的决策线，不是已达成结果。若行为指标与主观评价冲突，以行为证据为主，并通过访谈解释原因。

假设结论分级

结论	定义	产品动作
支持	关键行为指标达到标准，且多数访谈证据一致	保留并进入 PRD
部分支持	只对部分用户、样本或条件有效	缩小场景或修改设计后复测
未支持	没有改善，或带来明确错误和负担	降低优先级、替换方案或删除
证据不足	样本、材料或测试执行无法形成可靠判断	补充材料和参与者后再测

十二 测试后量表

使用 1 至 7 分量表：1 表示非常不同意，7 表示非常同意。评分后要求参与者为最低分和最高分各补充一句原因。

1. 我能理解模型置信评分表达的是相对可信程度，而不是事实正确概率。
2. 模型置信评分帮助我安排审核顺序或作出判断。
3. 关键路径帮助我理解候选事实为何被推荐。
4. 路径信息的数量和复杂度适合当前任务。
5. 接受、驳回和暂缓能够表达我的实际判断。
6. 我能在没有路径证据时继续完成审核。
7. 审核结果和导出范围能够满足后续图谱更新或分析需要。
8. 如果处理真实任务，我愿意使用这一工作台辅助审核。

十三 访谈提纲

1. 你刚才判断候选时最先看什么？为什么？
2. 模型评分改变了哪些决定？有没有让你犹豫或误导的情况？
3. 路径在什么情况下有帮助？哪些路径看了仍然无法判断？
4. 当候选没有路径时，你还需要哪些信息？
5. 接受、驳回、暂缓是否足够？是否需要“重复”“需专家复核”等独立状态？
6. 你通常会怎样分批处理大量候选？还需要哪些筛选或排序？
7. 导出的哪些字段可以直接使用？还缺少任务、来源、模型版本或审核日志中的哪些信息？
8. 如果只能保留一个功能，你会保留什么？如果必须删除一个功能，你会删除什么？
9. 什么条件满足后，你才会把它用于真实数据？

十四 观察记录表

参与者	角色/经验	测试日期	条件顺序	主持人

任务	独立完成	耗时	提示级别	错误/停顿	关键原话
T1 导入					
T2 创建任务					
T3 开始审核					
T4 判断候选					
T5 无路径					
T6 更正					
T7 导出					

问题严重度

等级	定义	处理要求
S0 观察	偏好或轻微建议，不影响任务	记录，结合频次判断
S1 轻微	造成短暂停顿，但能自行恢复	下一轮优化
S2 严重	需要提示或导致错误结果	进入优先迭代清单
S3 阻断	无法完成核心任务或产生不可恢复错误	正式 PRD 前必须修复并复测

十五 数据分析与需求决策

1. 先检查数据完整性：计时、条件、题组、答案和提示记录是否齐全。
2. 按参与者和条件计算准确率、耗时、正确审核吞吐量、暂缓率与判断信心。
3. 比较 B 与 A 以判断评分价值，比较 C 与 B 以判断路径增量价值。
4. 单独分析高分错误、低分正确、无路径和证据不足样本，识别平均值掩盖的风险。

- 5. 将观察问题按页面、任务、严重度和发生人数归类，合并重复问题。
- 6. 把量表、访谈原话与行为数据互相核对，避免只依据用户口头偏好。
- 7. 逐条更新 H1 至 H8 结论，并为每个产品改动记录对应证据。

发现	证据	影响	建议动作	优先级	负责人
示例：用户把 0.92 理解为 92%正确率	4/6 人明确这样表述	可能盲从评分	强化术语说明与校准提示并复测	P0	产品/算法

十六 需求验证报告模板

章节	需要填写的内容
1. 测试概况	日期、版本、参与者构成、测试方式、有效样本数
2. 关键结论	3 至 5 条最重要发现，先写行为证据再写解释
3. 指标结果	A/B/C 准确率、耗时、吞吐量、信心及个体数据
4. 假设判定	H1 至 H8 的支持、部分支持、未支持或证据不足
5. 可用性问题	问题、发生人数、严重度、对应页面和原话
6. 需求变更	保留、修改、删除和新增项，以及证据来源
7. 原型迭代	页面修改说明、负责人、优先级和复测要求
8. 决策建议	是否进入正式 PRD、高保真和真实模型接入

单条假设结论模板

H_：假设名称

结论：支持 / 部分支持 / 未支持 / 证据不足

行为证据：

访谈证据：

限制与替代解释：

产品决定：保留 / 修改 / 删除 / 继续验证

下一步：

十七 执行计划

阶段	工作	建议耗时	完成标准
准备	冻结原型、制作 18 条题目与参考答案、试跑	2 至 3 天	材料无明显歧义，记录表可用
招募	筛选并预约 6 至 8 名参与者	3 至 5 天	用户结构符合标准
预测试	完成 1 场内部预测试并修订脚本	0.5 天	单场时长和计时可控
正式测试	每天 1 至 2 场，双人记录	3 至 4 天	有效完成不少于 6 场
分析	清洗数据、归类问题、判断假设	2 天	形成证据表和迭代清单
汇报	输出需求验证报告和下一版原型范围	1 天	产品决策可追溯到证据

十八 风险与控制

风险	影响	控制措施
参与者不是目标用户	反馈偏向普通网页易用性	使用筛选题并记录经验层级
公开数据难以人工判断	参考答案不可靠	选取可理解子集并由两人独立标注
题组难度不等价	A/B/C 差异来自题目	按类型配额组题并轮换映射
主持人暗示	放大产品效果	统一脚本、限制提示并记录
模拟评分过于理想	无法发现盲从风险	保留高分错误和低分正确
样本量过小	结果波动大	呈现个体数据，首轮只作方向判断

风险	影响	控制措施
录屏或原始数据泄露	参与者隐私风险	匿名编号、最小化采集、限定访问和保存周期

十九 测试完成后的产品决策

当 P0 假设得到支持且不存在 S3 阻断问题时，可以进入正式 PRD 和高保真设计；若评分或路径未体现增量价值，应先修改信息表达、校准方式或样本设计后复测；若核心审核闭环无法被目标用户自然理解，则应回到业务流程和目标场景，而不是直接增加视觉精细度。